

Arquitetura da Solução — Pipeline de Dados e IA

FIC DEV IA · Fundamentos de Dados para IA · Grupo 6 (Pedro Gomes, Victor Silva, Kristiann Rocha)

1. Visão Geral e Fluxo Integrado

A arquitetura atende integralmente aos 14 requisitos funcionais obrigatórios (RF01 a RF14) do Desafio Prático 1. O sistema opera como um pipeline reproduzível e automatizado: desde a ingestão multifonte (CSV e JSON) até a persistência relacional/NoSQL, indexação vetorial com IA, recomendação personalizada e dashboard no Apache Superset.




Figura 1. Representação gráfica da arquitetura integrada da solução (conforme Seção 8 do enunciado).

2. Detalhamento das Camadas do Pipeline

Camada	Tecnologia	Responsabilidade e Requisitos Atendidos
Fontes	CSV, JSON	Armazenamento bruto imutável: catálogo educacional (CSV), interações e comentários com tags (JSON). Preservação dos arquivos originais.
Ingestão & Limpeza	Python, Regex	Leitura sem inferência prematura (RF02), validação com classificação de anomalias e integridade referencial (RF03), tratamento, deduplicação (RF04) e emissão de resumo em JSON (RF05).
Dados Estruturados	PostgreSQL 18 (Schema 'desafio')	Schema isolado com 6 tabelas relacionais com PK, FK, restrições CHECK e integridade transacional com cursor único e suporte a rollback (RF06, RF11).
Semiestruturados	MongoDB 8.0 (NoSQL)	Armazenamento de comentários em documentos flexíveis com array de tags. Suporta buscas textuais, agregações e consultas otimizadas (RF07).
IA & Embeddings	Sentence-Transformers, pgvector	Modelo paraphrase-multilingual-MiniLM-L12-v2 gerando vetores densos de 384 dimensões salvos no PostgreSQL via pgvector com índice HNSW para busca semântica (RF08, RF09).
Recomendação	Motor Algorítmico Híbrido	Combina afinidade temática vetorial (Ivis) e engajamento histórico do aluno (Icur) com filtro eliminatório de concluídos (Iconc). Top-10 salvos no Postgres (RF10, RF11).
Apresentação	Apache Superset, REST API	Camada semântica em Views SQL (RF12) consumidas via Superset com 3 cartões de KPI, gráfico de barras, linhas temporal e 2 filtros nativos (RF13).

3. Decisões Arquiteturais e Boas Práticas DataOps

A arquitetura incorpora princípios de Engenharia de Dados e DataOps (conforme Seção 9 do enunciado):

Decisão / Prática	Justificativa e Impacto Arquitetural
Schema dedicado ('desafio')	Isola as tabelas do desafio sem exigir privilégios de superusuário (rolcreatedb=false). Permite testes idempotentes e recriação limpa sem afetar outros bancos.
Persistência Híbrida Poliglota	Separação estrita: Catálogo, usuários, interações e recomendações no PostgreSQL (onde integridade referencial, JOINS e transações ACID são vitais); comentários e tags no MongoDB (onde estrutura semiestruturada e flexibilidade de documentos NoSQL são naturais).
Tratamento do Cold Start	O motor de recomendação adota a via vetorial de Ivis (centroide vetorial dos interesses do usuário cruzado com os conteúdos candidatos). Isso mitiga o problema dos 375 conteúdos sem interações prévias.
Transações e Idempotência	Toda a carga do PostgreSQL utiliza um cursor único gerenciado com transação completa (rollback total em caso de falha). Tabelas usam ON CONFLICT para garantir idempotência.
Segurança e Configuração (RF01)	Separação estrita: config.yaml versionado para parâmetros de negócio e arquivo .env isolado no .gitignore para senhas e credenciais de conexão.
Observabilidade e Auditoria (RF14)	Módulo de telemetria centralizado (src/log.py) registrando cronometragem de cada etapa, contagem de registros rejeitados e diagnóstico de falhas em formato estruturado saída/execucao.json.
Automação Superset via API REST	Criação e exportação de dashboards 100% programática via chamadas REST HTTP, eliminando dependência de interação manual na interface gráfica.

4. Matriz de Requisitos Funcionais (RF01 a RF14)

RF	Descrição	Módulo de Código	Artefato / Saída Gerada
RF01	Inicialização e Configuração	src/main.py, src/config.py	config.yaml, .env
RF02	Leitura das Fontes	src/ingestao/leitura.py	dados/brutos/ (CSV, JSON)
RF03	Validação dos Dados	src/ingestao/validacao.py	50 Testes em tests/
RF04	Tratamento e Padronização	src/ingestao/tratamento.py	dados/processados/
RF05	Resumo da Ingestão	src/ingestao/resumo.py	saida/resumo_ingestao.json
RF06	Persistência no PostgreSQL	src/carga/postgres.py	sql/criar_banco.sql
RF07	Persistência no MongoDB	src/carga/mongo.py	mongodb/consultas.js
RF08	Embeddings e pgvector	src/vetorial/embeddings.py	Tabela conteudo_embedding
RF09	Busca Semântica	src/vetorial/busca.py	saida/buscas.json
RF10	Geração de Recomendações	src/recomendacao/motor.py	Fórmula (Ivis+Icur)*100*Iconc
RF11	Persistência Recomendações	src/recomendacao/motor.py	Tabela recomendacao (Top-10)
RF12	Métricas e KPIs	sql/consultas.sql	documentacao/kpis.md
RF13	Dashboard no Superset	src/dashboard/montar.py	dashboard/desafio_1.zip
RF14	Registro de Execução	src/log.py	saida/execucao.json